

基于双边滤波与引导滤波的低光照图像增强实验报告

作者信息待填写

学号待填写

Abstract

本文围绕低光照图像增强任务，基于 Retinex 思想构建了一套完整的实验流程。方法上，首先利用 RGB 三通道最大值估计初始照明图，再分别采用双边滤波和引导滤波对照明图进行边缘保持平滑，最后通过照明补偿公式恢复增强结果；在此基础上，进一步设计了保持增强亮度不变、利用原图色度信息进行自适应融合的线性色彩校正方法。实验以题目提供的 10 组低光照图像与 Ground Truth 配对样本为对象，采用 PSNR、SSIM、MAE、MSE、LPIPS 及 Lab 空间 Δab 等指标进行定量分析，并结合中间照明图、增强结果和热力图进行定性比较。结果表明，引导滤波在默认参数下整体优于双边滤波，关键参数对增强质量具有明显影响；同时，线性色彩校正能够在基本保持原有亮度结构的前提下进一步减小色差，改善视觉一致性。

1. 研究现状及主要研究方法

低光照图像通常存在亮度不足、暗区细节难以辨识、噪声显著以及色彩失真等问题。传统方法中，Retinex 理论认为图像可以表示为反射分量与照明分量的乘积，即

$$I(x) = R(x) \cdot T(x), \quad (1)$$

其中 $I(x)$ 为观测图像， $R(x)$ 对应反射信息， $T(x)$ 对应照明信息。低光照增强的基本思想是在估计照明分量后对其进行补偿，从而恢复更合理的反射结果 [6]。

从研究路线看，低光照增强大致可以分为三类。第一类是基于图像先验的传统方法，例如直方图均衡、Gamma 校正、Retinex 系列方法以及基于照明图估计的方法。LIME 通过直接估计照明图并施加结构先验，证明了照明建模对增强质量的重要性 [2]。第二类是基

于边缘保持滤波的增强方法，这类方法通常先从输入图像中估计粗略照明图，再通过双边滤波或引导滤波抑制纹理和噪声，兼顾平滑性与边缘保持 [4, 5, 7]。第三类是深度学习方法，包括 Retinex-Net、KinD、Zero-DCE 等代表性工作，它们能够在大规模训练数据上学习更复杂的亮度映射或分解关系，但通常依赖训练数据、计算资源和更复杂的模型设计 [1, 9, 11]。

近年来的综述研究指出，传统方法在可解释性、实现成本和小样本场景中仍具有优势，而学习型方法在视觉质量和泛化能力上表现更强 [3]。除亮度恢复外，颜色失真也是低光照增强中的常见问题，许多增强方法在提升亮度的同时会引入偏色、饱和度不稳定或局部色彩漂移，因此颜色校正或颜色约束同样是提升结果自然性的重要环节。对本次课程作业而言，基于双边滤波与引导滤波的 Retinex 型方法具有结构清晰、参数可解释、便于展示中间结果和分析实验现象等优点，因此本文以其作为主体增强框架，并进一步引入利用原图色度信息的线性色彩校正，构成“亮度恢复 + 色彩修正”的完整实验方案。

2. 本文研究方法

2.1. 初始照明图估计

设输入 RGB 低光照图像为 I ，首先将其归一化到 $[0, 1]$ ，再按照题目要求采用三通道最大值估计初始照明图：

$$T_0(x) = \max\{I_R(x), I_G(x), I_B(x)\}. \quad (2)$$

该估计方式实现简单，能够快速反映局部亮度水平，但直接得到的 T_0 往往混入纹理细节、边缘和噪声，因此不能直接作为最终照明图使用。

2.2. 照明图平滑

为了得到更符合真实照明分布的结果，本文分别采用双边滤波和引导滤波对 T_0 进行边缘保持平滑。

双边滤波 双边滤波在邻域加权平均时同时考虑空间距离和像素值相似性，其形式为

$$T_b(x) = \frac{1}{W_x} \sum_{y \in \Omega(x)} G_s(\|x-y\|) G_r(|T_0(x)-T_0(y)|) T_0(y), \quad (3)$$

其中 $G_s(\cdot)$ 和 $G_r(\cdot)$ 分别对应空间域权重和值域权重， W_x 为归一化因子 [7]。本文实现中使用 OpenCV 的双边滤波接口，重点调节邻域直径 d 、值域参数 σ_{color} 和空间域参数 σ_{space} 。

引导滤波 引导滤波假设在局部窗口 ω_k 内，输出 q 与引导图像 G 满足线性关系

$$q_i = a_k G_i + b_k, \quad i \in \omega_k. \quad (4)$$

在最小二乘与正则化约束下，可求得局部系数

$$a_k = \frac{\text{cov}_{\omega_k}(G, p)}{\text{var}_{\omega_k}(G) + \epsilon}, \quad b_k = \bar{p}_k - a_k \mu_k, \quad (5)$$

其中 p 为待滤波图像， ϵ 为正则项 [4, 5]。本文采用自引导方案，即 $G = T_0, p = T_0$ ，并以窗口半径 r 与正则参数 ϵ 控制平滑尺度。

2.3. 照明补偿与增强恢复


在得到平滑后的照明图 T 后，对输入图像进行照明补偿，增强公式写为

$$J_c(x) = \frac{I_c(x)}{\max(T(x), T_{\min})^\gamma}, \quad (6)$$


其中 $J_c(x)$ 表示输出图像在通道 c 上的像素值， $T_{\min}$ 用于避免极暗区域分母过小导致数值不稳定， γ 用于调节增强强度。增强后再将结果裁剪到 $[0, 1]$ ，以便保存图像和计算指标。

2.4. 线性色彩校正


在增强结果基础上，本文进一步引入线性色彩校正，以缓解增强后可能出现的偏色和局部色彩漂移。设原图的 Lab 表示为 (L_i, a_i, b_i) ，增强结果的 Lab 表示



(a) 初始照明图 T_0



(b) 双边滤波平滑结果



(c) 引导滤波平滑结果

图 1. 样本 00017.png 的中间结果示意。双边滤波得到的照明图更平滑，但边缘附近略有扩散；引导滤波保留了更多结构边界。

为 (L_j, a_j, b_j) ，则保持增强结果亮度分量 L_j 不变，仅对色度分量进行融合：

$$a'_j = (1 - \alpha)a_j + \alpha a_i, \quad (7)$$

$$b'_j = (1 - \alpha)b_j + \alpha b_i, \quad (8)$$

其中

$$\alpha(x) = \alpha_{\max} \cdot \frac{L_i(x)}{100}. \quad (9)$$

最终校正结果写为

$$J_{cc} = \text{Lab}^{-1}(L_j, a'_j, b'_j). \quad (10)$$

该设计的直观含义是：亮度结构完全保留增强结果，而颜色信息由增强结果与原图色度共同决定。由于原图亮区的颜色通常比极暗区域更可靠，因此通过原图亮度 L_i 对融合系数进行调制，使较亮区域更多参考原图色度，暗区则减少原图噪声色度的影响。本文默认取 $\alpha_{\max} = 0.5$ 。

2.5. 算法流程

本文方法可以概括为以下步骤：

1. 读取低光照图像并归一化；
2. 通过 RGB 三通道最大值估计初始照明图 T_0 ；
3. 对 T_0 分别采用双边滤波或自引导滤波进行平滑；
4. 利用平滑照明图和增强公式恢复增强结果；
5. 在增强结果基础上，结合原图 Lab 色度信息执行线性色彩校正；
6. 将增强结果与 Ground Truth 进行对比，计算 PSNR、SSIM、MAE、MSE、LPIPS 以及 Δab 等指标 [8, 10]。

表 1. 默认参数下两种方法的平均指标对比

方法	PSNR↑	SSIM↑	MAE↓	MSE↓	LPIPS↓
双边滤波	18.3094	0.6109	0.1135	0.0196	0.2544
引导滤波	18.4591	0.6285	0.1122	0.0193	0.2486




图 2. 默认参数下双边滤波与引导滤波的平均指标对比图。

3. 实验结果

3.1. 实验设置

实验数据采用题目提供的 `samples/Train/Input` 与 `samples/Train/GT`, 共 10 对配对图像。默认参数设置如下: 双边滤波为 $d = 15, \sigma_{color} = 0.1, \sigma_{space} = 15$; 引导滤波为 $r = 8, \epsilon = 10^{-3}$; 增强参数为 $T_{min} = 0.1, \gamma = 0.8$ 。其中, PSNR、SSIM 越大越好, MAE、MSE、LPIPS 越小越好。


3.2. 默认参数下的方法对比

表 1 给出了默认参数下双边滤波与引导滤波的平均结果。可以看到, 引导滤波在五项指标上整体优于双边滤波, 其中 PSNR 提升约 0.15 dB, SSIM 提升 0.0176, LPIPS 降低 0.0058。这说明在当前任务中, 引导滤波得到的照明图更有利于保留结构边缘并抑制不必要的亮度扩散。


进一步查看逐图像结果可知, 引导滤波在 10 张样本上均取得更高的 PSNR 与 SSIM; 在 LPIPS 上, 引导滤波在 8 张样本上优于双边滤波, 仅在 00001.png 和 00051.png 上略逊于双边滤波。这表明两种方法在大多数场景下趋势一致, 但感知指标与像素级指标并不总是完全同步。

3.3. 定性结果分析

图 3 展示了较困难样本 00017.png 的结果。该样本原图照明极弱, 桌面下方和窗帘区域均存在大面积暗区。两种方法都能显著提升可见性, 但增强后仍可观




(a) 双边滤波结果



(b) 引导滤波结果

图 3. 困难样本 00017.png 的定性结果。每行从左到右分别为输入图像、增强结果和 Ground Truth。



(a) 00051.png



(b) 00091.png

图 4. 两个代表性样本的引导滤波增强结果。每行从左到右分别为输入图像、增强结果和 Ground Truth。

察到明显噪声, 且与 GT 相比存在亮度偏差, 因此其 PSNR 仅约为 11.9 dB。结合图 1 可见, 双边滤波后的照明图更加平滑, 导致增强结果整体略显“泛灰”; 引导滤波保留了更多局部结构, 因而 SSIM 略高。

图 4 展示了两个较稳定样本的结果。对 00051.png 而言, 引导滤波在植物叶片和椅背边缘处保留了更清晰的结构; 对 00091.png 而言, 引导滤波能够更好地恢复炉灶边界和锅体轮廓, 同时控制墙面区域的亮度泄漏。两者共同说明, 引导滤波在结构清晰的场景下更容易获得与 GT 接近的亮度分布。

3.4. 参数敏感性分析

为分析中间设计对结果的影响, 本文进一步对双边滤波的三个关键参数 d 、 σ_{color} 和 σ_{space} 进行了更宽范围的控制变量实验; 同时扩展了引导滤波的窗口半径 r 、正则参数 ϵ 以及增强参数 T_{min} 、 γ 的实验范围。各组实验均固定其余参数为默认值, 仅改变单个参数。

表 2. 双边滤波邻域直径 d 的影响

d	PSNR↑	SSIM↑	LPIPS↓
3	18.2614	0.6104	0.2622
5	18.2701	0.6106	0.2767
9	18.2841	0.6108	0.2618
15	18.3094	0.6109	0.2544
25	18.3460	0.6130	0.2516
35	18.3785	0.6153	0.2508




图 5. 双边滤波邻域直径变化对平均指标的影响。




图 6. 双边滤波值域参数变化对平均指标的影响。

双边滤波邻域直径 d 表 2 与图 5 给出了 $d = 3, 5, 9, 15, 25, 35$ 时的结果。随着邻域直径增大, PSNR、SSIM 持续上升, LPIPS 整体下降, 其中 $d = 35$ 时达到最优。这说明在当前数据集上, 较大的邻域窗口有助于对照明图进行更充分的局部平均, 使增强结果在整体亮度分布上更接近 GT; 但从中间照明图可见, 过大的 d 会扩大平滑尺度, 弱化局部照明边界。

双边滤波值域参数 σ_{color} 表 3 与图 6 展示了 $\sigma_{color} = 0.01, 0.03, 0.05, 0.10, 0.20, 0.40$ 时的实验结果。随着 σ_{color} 增大, SSIM 近似单调下降, 而 PSNR 呈现先升后降的趋势, 在 $\sigma_{color} = 0.05$ 附近取得最高值; LPIPS 在 $\sigma_{color} = 0.20$ 时最优。该现象说明较小的 σ_{color} 更强调值域相似性, 对跨边缘混合的抑制更强, 因此结构指标更高; 当 σ_{color} 过大时, 边缘约束减弱, 照明图容易被过度平滑, 细节结构损失更明显。

表 3. 双边滤波值域参数 σ_{color} 的影响

σ_{color}	PSNR↑	SSIM↑	LPIPS↓
0.01	18.2763	0.6257	0.2641
0.03	18.3058	0.6214	0.2627
0.05	18.3311	0.6181	0.2578
0.10	18.3094	0.6109	0.2544
0.20	18.2777	0.6057	0.2542
0.40	18.2550	0.6035	0.2546

表 4. 双边滤波空间域参数 σ_{space} 的影响

σ_{space}	PSNR↑	SSIM↑	LPIPS↓
3	18.3106	0.6127	0.2576
7	18.3107	0.6113	0.2547
15	18.3094	0.6109	0.2544
30	18.3091	0.6108	0.2543
60	18.3090	0.6108	0.2543
90	18.3090	0.6108	0.2543




图 7. 双边滤波空间域参数变化对平均指标的影响。

双边滤波空间域参数 σ_{space} 表 4 与图 7 给出了 $\sigma_{space} = 3, 7, 15, 30, 60, 90$ 时的结果。与前两个参数相比, σ_{space} 对五项平均指标的影响明显更弱, 各组结果几乎保持稳定, 仅在较小的 σ_{space} 下 SSIM 略高。这表明在当前默认直径 $d = 15$ 的设定下, 空间域高斯衰减在有效邻域内已经较为稳定, 继续增大 σ_{space} 并不会显著改变权重分布。

综合上述三组实验可以看出, 双边滤波在当前任务中对邻域直径 d 最敏感, 其次是值域参数 σ_{color} , 而空间域参数 σ_{space} 的影响最小。若目标是提升像素级保真与整体感知质量, 则较大的 d 和中等偏小的 σ_{color} 更有利; 若强调结构保持, 则应避免将 σ_{color} 取值过大。




图 8. 样本 00017.png 在双边滤波不同参数下的照明图平滑结果。可以看到, d 和 σ_{color} 对局部结构影响更明显, 而 σ_{space} 的变化相对较弱。

表 5. 引导滤波半径 r 的影响

r	PSNR $\uparrow$	SSIM $\uparrow$	MAE $\downarrow$	MSE $\downarrow$	LPIPS $\downarrow$
2	18.3217	0.6192	0.1144	0.0199	0.2631
4	18.3751	0.6229	0.1136	0.0196	0.2546
8	18.4591	0.6285	0.1122	0.0193	0.2486
16	18.5615	0.6338	0.1105	0.0188	0.2432
24	18.6199	0.6357	0.1095	0.0185	0.2402
32	18.6570	0.6368	0.1088	0.0183	0.2386

引导滤波半径 r 表 5 与图 9 给出了 6 组窗口半径实验结果。可以看到, 在 $r = 2$ 到 $r = 32$ 的测试范围内, PSNR 与 SSIM 持续上升, MAE、MSE 与 LPIPS 持续下降, 说明更大的局部窗口有助于在更大尺度上估计照明趋势, 减少初始照明图中的纹理残留。以 $r = 2$ 与 $r = 32$ 对比为例, PSNR 从 18.3217 dB 提升到 18.6570 dB, SSIM 从 0.6192 提升到 0.6368, LPIPS 从 0.2631 降低到 0.2386, 表明 guided filter 在当前数据范围内尚未出现因窗口过大而导致的明显过平滑。




图 9. 引导滤波半径变化对平均指标的影响。

表 6. 引导滤波正则参数 ϵ 的影响

ϵ	PSNR $\uparrow$	SSIM $\uparrow$	MAE $\downarrow$	MSE $\downarrow$	LPIPS $\downarrow$
10^{-6}	18.2727	0.6280	0.1156	0.0202	0.2663
10^{-5}	18.2822	0.6299	0.1155	0.0202	0.2612
10^{-4}	18.3318	0.6317	0.1147	0.0200	0.2542
10^{-3}	18.4591	0.6285	0.1122	0.0193	0.2486
10^{-2}	18.3970	0.6138	0.1112	0.0190	0.2499
10^{-1}	18.3121	0.6067	0.1114	0.0191	0.2521






图 10. 引导滤波正则参数变化对平均指标的影响。

引导滤波正则参数 ϵ 正则参数 ϵ 控制局部线性模型对方差项的抑制强度。表 6 与图 10 显示, ϵ 对结果的影响呈现明显的折中关系。 ϵ 过小时, 局部模型过于贴近原始 T_0 , 导致纹理和噪声残留较多; ϵ 过大时, 局部线性系数被过度约束, 结构边界会被额外平滑, 进而使 SSIM 明显下降。在当前实验中, $\epsilon = 10^{-3}$ 取得最高 PSNR 和最低 LPIPS, 而 $\epsilon = 10^{-4}$ 的 SSIM 略高, 说明像素保真、结构一致性和感知质量的最优点并不完全重合。进一步增大到 $\epsilon = 10^{-2}$ 与 10^{-1} 后, 虽然 MAE/MSE 仍保持较低水平, 但 SSIM 从 0.6285 降至 0.6138 和 0.6067, 说明过强的正则化会削弱局部结构恢复能力。


增强下限参数 $T_{\min}$ $T_{\min}$ 用于限制分母中的最小照明值, 从而避免极暗区域被过度放大。表 7 与图 12 显示, $T_{\min}$ 的变化同样会显著影响增强结果, 但其影响方式与 γ 不同。较小的 $T_{\min}$ 会允许更强的暗区补偿, 因此



(a) $r = 2$ 时的平滑照明图



(b) $r = 32$ 时的平滑照明图



(c) $\epsilon = 10^{-6}$ 时的平滑照明图



(d) $\epsilon = 10^{-1}$ 时的平滑照明图

图 11. 样本 00017.png 在不同引导滤波参数下的平滑照明图对比。增大半径会使照明估计更趋于全局一致；过大的 ϵ 会减弱局部结构响应，使边界区域出现更明显的平滑。

在像素误差指标上可能更有优势，例如 $T_{\min} = 0.05$ 时取得最高 PSNR 18.8776 dB 和最低 MSE 0.0153；但此时暗区噪声也更容易被放大，导致 LPIPS 仍处于较高水平。随着 $T_{\min}$ 增大到 0.10 和 0.15，补偿强度逐渐受限，图像整体更加稳定，结构相似性和感知质量更好，其中 $T_{\min} = 0.15$ 取得最高 SSIM 0.6291 和最低 LPIPS 0.2362。若继续增大到 0.25，则会明显压制暗区恢复，整体图像偏暗，PSNR 与 SSIM 同时下降。综合来看， $T_{\min}$ 控制的是“是否允许极暗区域被大幅拉升”，因此它在保真、结构和感知指标之间体现出明显的多目标折中。

表 7. 增强下限参数 $T_{\min}$ 的影响（基于引导滤波）

$T_{\min}$	PSNR $\uparrow$	SSIM $\uparrow$	MAE $\downarrow$	MSE $\downarrow$	LPIPS $\downarrow$
0.02	18.3716	0.5912	0.1001	0.0166	0.3086
0.05	18.8776	0.6067	0.0974	0.0153	0.2845
0.08	18.8741	0.6219	0.1023	0.0166	0.2616
0.10	18.4591	0.6285	0.1122	0.0193	0.2486
0.15	15.7750	0.6291	0.1648	0.0348	0.2362
0.25	11.3799	0.5631	0.2678	0.0819	0.2490




图 12. 增强下限参数 $T_{\min}$ 变化对平均指标的影响。



(a) $T_{\min} = 0.02$



(b) $T_{\min} = 0.05$



(c) $T_{\min} = 0.08$



(d) $T_{\min} = 0.10$



(e) $T_{\min} = 0.15$



(f) $T_{\min} = 0.25$

图 13. 样本 00017.png 在不同增强下限参数下的增强结果。较小的 $T_{\min}$ 会更强烈地拉升暗区，同时更容易放大噪声；较大的 $T_{\min}$ 则会抑制过增强，但也可能使整体亮度恢复不足。

增强指数 γ 增强公式中的 γ 直接控制照明补偿强度，因此其影响最为直观。表 8 与图 14 显示，在本实验选取的 6 组参数中， $\gamma = 0.8$ 的综合表现最好，其 PSNR、

表 8. 增强指数 γ 的影响（基于引导滤波）

γ	PSNR $\uparrow$	SSIM $\uparrow$	MAE $\downarrow$	MSE $\downarrow$	LPIPS $\downarrow$
0.4	9.2020	0.4763	0.3342	0.1283	0.2688
0.6	12.2243	0.6090	0.2403	0.0675	0.2430
0.8	18.4591	0.6285	0.1122	0.0193	0.2486
1.0	14.3550	0.5360	0.1671	0.0410	0.3148
1.2	10.6393	0.5185	0.2632	0.0951	0.4570
1.4	8.7632	0.4750	0.3256	0.1396	0.5777




图 14. 增强指数 γ 变化对平均指标的影响。

SSIM 分别达到 18.4591 dB 和 0.6285，同时保持较低的 MSE 与较好的 LPIPS。与之相比，较小的 $\gamma = 0.4$ 和 $\gamma = 0.6$ 会导致增强不足，大面积暗区无法被充分拉升，因此像素误差较大；而当 γ 增大到 1.0 以上时，亮度补偿过强，噪声和局部失真被同步放大，SSIM、PSNR 与 LPIPS 均显著恶化。例如，当 γ 从 0.8 增加到 1.4 时，PSNR 从 18.4591 dB 下降到 8.7632 dB，LPIPS 从 0.2486 恶化到 0.5777，说明过增强对定量质量破坏非常明显。

3.5. 线性色彩校正实验

在前述增强结果的基础上，仍可观察到部分样本存在较明显的色偏。以 00051.png 和 00091.png 为例，guided 默认参数增强后的亮度恢复已经较为充分，但植物边缘、锅体高亮区域和墙面过渡区域仍出现与 Ground Truth 不一致的色度偏移。为了定量描述这一现象，本文继续采用 Lab 空间中忽略亮度后的色度距离

$$\Delta ab(x) = \sqrt{(a(x) - a_{GT}(x))^2 + (b(x) - b_{GT}(x))^2}, \quad (11)$$

并将其绘制为热力图。图 16 表明，两张代表样本的高误差区域主要集中在暖色高亮边界、植物叶片反光以及局部暗区纹理处，这说明单纯依赖增强后的色度响应仍会带来一定的颜色漂移。




图 15. 样本 00017.png 在不同增强指数下的增强结果。较小的 γ 会导致整体偏暗、增强不足；较大的 γ 虽能显著提亮暗区，但会同时带来更强的噪声放大和局部过曝。




图 16. 默认 guided 增强结果的 Lab 色度距离热力图。暖色高亮边缘和局部材质纹理处的色差更明显。

在前述方法基础上，本文进一步考察线性色彩校正对最终结果的影响。该步骤保持增强结果亮度不变，并利用原图较可信区域的色度信息对增强结果进行自适应回拉，因此既能保持亮度恢复效果，又能在一定程度上缓解颜色漂移。




图 17. 线性色彩校正的代表性结果。每行从左到右分别为输入图像、线性色彩校正结果和 Ground Truth。

表 9. 代表样本在线性色彩校正前后的指标对比

样本	结果	PSNR↑	SSIM↑	LPIPS↓	Δab ↓
00051	增强前	21.3701	0.6567	0.2196	11.2778
	校正后	21.6306	0.6644	0.2171	10.5267
00091	增强前	23.4170	0.5993	0.3178	6.9758
	校正后	23.4927	0.6081	0.3156	6.6622

表 9 给出了两张代表样本在线性色彩校正前后的指标变化。可以看到，线性色彩校正 在 00051.png 和 00091.png 上均同时改善了 PSNR、SSIM、LPIPS 与 Δab 。其中 00051.png 的 Δab 从 11.2778 降至 10.5267，00091.png 的 Δab 从 6.9758 降至 6.6622。虽然改变量小于强全局压缩型方法，但视觉上保留了更多增强结果自身的色彩氛围，同时对高亮边缘的色偏有一定抑制作用。

从整组测试集的平均结果来看，线性色彩校正同样带来了稳定提升。表 10 显示，在默认 guided 参数 $r = 8, \epsilon = 10^{-3}, T_{\min} = 0.1, \gamma = 0.8$ 下，加入线性色彩校正后，平均 PSNR 从 18.4591 dB 提升到 18.5382 dB，SSIM 从 0.6285 提升到 0.6353，LPIPS 从 0.2486 下降到 0.2466， Δab 从 9.5235 下降到 9.0655。说明原图色度先验虽然较弱，但通过亮度自适应融合后，仍能对增强结果提供稳定的颜色约束。

图 18 给出了线性色彩校正后的 Δab 热力图。与图 16 对比可见，00051 的植物和椅背高亮边缘、00091 的锅体高亮边界处，暖色高误差区域均有所收缩。由于该方法仅在色度上做线性融合，且暗区的 $\alpha(x)$ 较小，因

表 10. 默认 guided 参数下线性色彩校正的平均指标

结果	PSNR↑	SSIM↑	LPIPS↓	Δab ↓
增强结果	18.4591	0.6285	0.2486	9.5235
线性色彩校正后	18.5382	0.6353	0.2466	9.0655



(a) 00051.png 校正后的 Δab 热力图



(b) 00091.png 校正后的 Δab 热力图

图 18. 线性色彩校正的 Lab 色度距离热力图。高色差区域较增强前有所减弱，但整体色彩风格保持更接近增强结果。

此它不会像强全局压缩那样显著改变整幅图像的色彩风格，而更偏向于一种保守的颜色回拉。

融合上限参数 $\alpha_{\max}$ 为分析原图色度参与程度对结果的影响，本文在默认 guided 参数下，进一步测试了 $\alpha_{\max} = 0.0, 0.1, 0.2, 0.3, 0.4, 0.5$ 六组取值。表 11 与图 19 显示，在当前数据集上，随着 $\alpha_{\max}$ 增大，PSNR、SSIM 持续上升，而 Δab 与 LPIPS 持续下降，呈现较稳定的单调趋势。以极值组为例，当 $\alpha_{\max}$ 从 0 增加到 0.5 时，平均 PSNR 从 18.4357 dB 提升到 18.5382 dB，SSIM 从 0.6284 提升到 0.6353， Δab 从 9.5096 降至 9.0655。说明在当前实验范围内，原图色度先验仍未被过度使用，较大的融合上限反而更有利于抑制增强结果中的颜色漂移。

图 20 给出了样本 00051.png 在不同 $\alpha_{\max}$ 下的视觉结果。随着 $\alpha_{\max}$ 增大，叶片边缘和木质区域的色调逐渐向原图颜色方向回拉，但由于 $\alpha(x)$ 仍受到原图亮度调制，暗区没有出现明显的颜色噪声放大。在当前测

表 11. 线性色彩校正中 $\alpha_{\max}$ 的影响

$\alpha_{\max}$	PSNR $\uparrow$	SSIM $\uparrow$	LPIPS $\downarrow$	$\Delta ab \downarrow$
0.0	18.4357	0.6284	0.2487	9.5096
0.1	18.4574	0.6298	0.2482	9.3790
0.2	18.4785	0.6312	0.2478	9.3047
0.3	18.4989	0.6326	0.2474	9.2256
0.4	18.5188	0.6340	0.2470	9.1457
0.5	18.5382	0.6353	0.2466	9.0655




图 19. 融合上限参数 $\alpha_{\max}$ 变化对平均指标的影响。




图 20. 样本 00051.png 在不同 $\alpha_{\max}$ 下的线性色彩校正结果。从左到右、从上到下依次为 $\alpha_{\max} = 0.0, 0.1, 0.2, 0.3, 0.4, 0.5$ 。

试范围内， $\alpha_{\max} = 0.5$ 提供了最明显且仍然稳定的校正效果，因此本文将其作为线性色彩校正的默认设置。

4. 总结

本文完成了一个基于 Retinex 思想的低光照图像增强实验系统，重点比较了双边滤波与引导滤波两种照明图平滑方式，并通过定量与定性实验分析了关键参数及线性色彩校正对结果的影响。实验表明：

1. 在默认参数下，引导滤波优于双边滤波，说明局部线性约束更适合本作业数据中的照明图细化；
2. 对双边滤波而言，邻域直径 d 的影响最显著，值域参数 σ_{color} 次之，而空间域参数 σ_{space} 的影响最弱；

3. 对引导滤波而言，较大的窗口半径在当前样本上表现更稳定，而正则参数 ϵ 则体现出明显的保边与过平滑折中；
4. 对增强参数而言， $T_{\min}$ 与 γ 共同控制暗区补偿幅度，其中较小的 $T_{\min}$ 有利于提升像素级误差指标，但更容易放大噪声； $\gamma = 0.8$ 在当前数据上取得了最平衡的结果，过小会增强不足，过大则会导致明显的过增强和感知质量恶化；
5. 在线性色彩校正阶段，利用原图 Lab 色度信息进行亮度自适应融合，能够在基本保持亮度结构的前提下进一步减小色差，改善颜色一致性。

本文方法的优点是结构清晰、实现简单、可解释性强，并且能够直接输出初始照明图、平滑照明图、增强结果以及颜色校正结果等中间步骤。其不足在于：第一，照明估计仍采用最大通道近似，难以应对复杂光照和严重色偏；第二，参数仍依赖人工设置，不同图像上的最优取值并不完全一致；第三，在极暗样本中，增强后仍会放大噪声，线性色彩校正对这类区域的改善也相对有限。后续可尝试更稳健的照明图先验、联合去噪机制，或引入学习型方法进一步提升结果。

参考文献

- [1] Chunle Guo, Chongyi Li, Jichang Guo, Chen Change Loy, Junhui Hou, Sam Kwong, and Runmin Cong. Zero-reference deep curve estimation for low-light image enhancement. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pages 1780–1789, 2020. 1
- [2] Xiaojie Guo, Yu Li, and Haibin Ling. Lime: Low-light image enhancement via illumination map estimation. IEEE Transactions on Image Processing, 26(2):982–993, 2017. 1
- [3] Xiaojie Guo, Yu Li, Haibin Ling, et al. A survey on image enhancement for low-light images. Heliyon, 9 (11):e21660, 2023. 1
- [4] Kaiming He, Jian Sun, and Xiaoou Tang. Guided image filtering. In Proceedings of the European Conference on Computer Vision, pages 1–14, 2010. 1, 2
- [5] Kaiming He, Jian Sun, and Xiaoou Tang. Guided image filtering. IEEE Transactions on Pattern Analysis and Machine Intelligence, 35(6):1397–1409, 2013. 1, 2
- [6] Edwin H. Land and John J. McCann. Lightness and

retinex theory. *Journal of the Optical Society of America*, 61(1):1–11, 1971. [1](#)

- [7] Carlo Tomasi and Roberto Manduchi. Bilateral filtering for gray and color images. In *Proceedings of the IEEE International Conference on Computer Vision*, pages 839–846, 1998. [1](#), [2](#)
- [8] Zhou Wang, Alan C. Bovik, Hamid R. Sheikh, and Eero P. Simoncelli. Image quality assessment: From error visibility to structural similarity. *IEEE Transactions on Image Processing*, 13(4):600–612, 2004. [2](#)
- [9] Chen Wei, Wenjing Wang, Wenhan Yang, and Jiaying Liu. Deep retinex decomposition for low-light enhancement. In *Proceedings of the British Machine Vision Conference*, 2018. [1](#)
- [10] Richard Zhang, Phillip Isola, Alexei A. Efros, Eli Shechtman, and Oliver Wang. The unreasonable effectiveness of deep features as a perceptual metric. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 586–595, 2018. [2](#)
- [11] Yonghua Zhang, Jiawan Zhang, and Xiaojie Guo. Kindling the darkness: A practical low-light image enhancer. *Proceedings of the ACM International Conference on Multimedia*, pages 1632–1640, 2019. [1](#)